Neste projeto, você deve prever o Customer Churn em uma Operadora de Telecom. Será criado um projeto de Regressão Logística com o PySpark - segundo recomendação - para prever se um cliente pode (sim = 1) ou não (0) cancelar seu plano.

Utilizei o Java 1.8 e Spark 2.4.2

Importando Pacotes e explorando o Dataset

In [16]:
```
# imports
import math
from pyspark.sql import SparkSession
import seaborn as sns
```

In [2]:
```
# Vou usar o Pandas para explorar o Dataset.
import pandas as pd
df = pd.read_csv('projeto4_telecom_treino.csv')
```

In [3]:
```
# Dimensões do dataset
df.shape
```

Out[3]:
```
(3333, 21)
```

In [4]:
```
# Visualizar dataset
df.head(5)
```

Out[4]:

	Unnamed: 0	state	account_length	area_code	international_plan	voice_mail_plan	number_vmail_messages	total_day_minutes	total_day_calls
0	1	KS	128	area_code_415	no	yes	25	265.1	110
1	2	OH	107	area_code_415	no	yes	26	161.6	123
2	3	NJ	137	area_code_415	no	no	0	243.4	114
3	4	OH	84	area_code_408	yes	no	0	299.4	71
4	5	OK	75	area_code_415	yes	no	0	166.7	113

5 rows × 21 columns

In [5]:
```
# Verificando se existem dados missing
df.isnull().any()
```

Out[5]:
```
Unnamed: 0                       False
state                            False
account_length                   False
area_code                        False
international_plan               False
voice_mail_plan                  False
number_vmail_messages            False
total_day_minutes                False
total_day_calls                  False
total_day_charge                 False
total_eve_minutes                False
total_eve_calls                  False
total_eve_charge                 False
total_night_minutes              False
total_night_calls                False
total_night_charge               False
total_intl_minutes               False
total_intl_calls                 False
total_intl_charge                False
number_customer_service_calls    False
churn                            False
dtype: bool
```

In [105]:
```
# Excluindo a coluna 0, pois é meramente indice.
df = df.drop('Unnamed: 0',axis=1)
```

In [106]:
```python
# Histogramas de todas as variáveis do dataset.
df.hist(figsize = (15,10))
```

Out[106]:
```
array([[<matplotlib.axes._subplots.AxesSubplot object at 0x00000185E2206BE0>,
        <matplotlib.axes._subplots.AxesSubplot object at 0x00000185E22DD2B0>,
        <matplotlib.axes._subplots.AxesSubplot object at 0x00000185E22ED6D8>,
        <matplotlib.axes._subplots.AxesSubplot object at 0x00000185E1D91C50>],
       [<matplotlib.axes._subplots.AxesSubplot object at 0x00000185E1DC1208>,
        <matplotlib.axes._subplots.AxesSubplot object at 0x00000185E1DE9780>,
        <matplotlib.axes._subplots.AxesSubplot object at 0x00000185E1E12CF8>,
        <matplotlib.axes._subplots.AxesSubplot object at 0x00000185E1E412E8>],
       [<matplotlib.axes._subplots.AxesSubplot object at 0x00000185E1E41320>,
        <matplotlib.axes._subplots.AxesSubplot object at 0x00000185E1E92DA0>,
        <matplotlib.axes._subplots.AxesSubplot object at 0x00000185E1EC3358>,
        <matplotlib.axes._subplots.AxesSubplot object at 0x00000185E1EE88D0>],
       [<matplotlib.axes._subplots.AxesSubplot object at 0x00000185E1F11E48>,
        <matplotlib.axes._subplots.AxesSubplot object at 0x00000185E1F41400>,
        <matplotlib.axes._subplots.AxesSubplot object at 0x00000185E1F68978>,
        <matplotlib.axes._subplots.AxesSubplot object at 0x00000185E1F8FEF0>]],
      dtype=object)
```

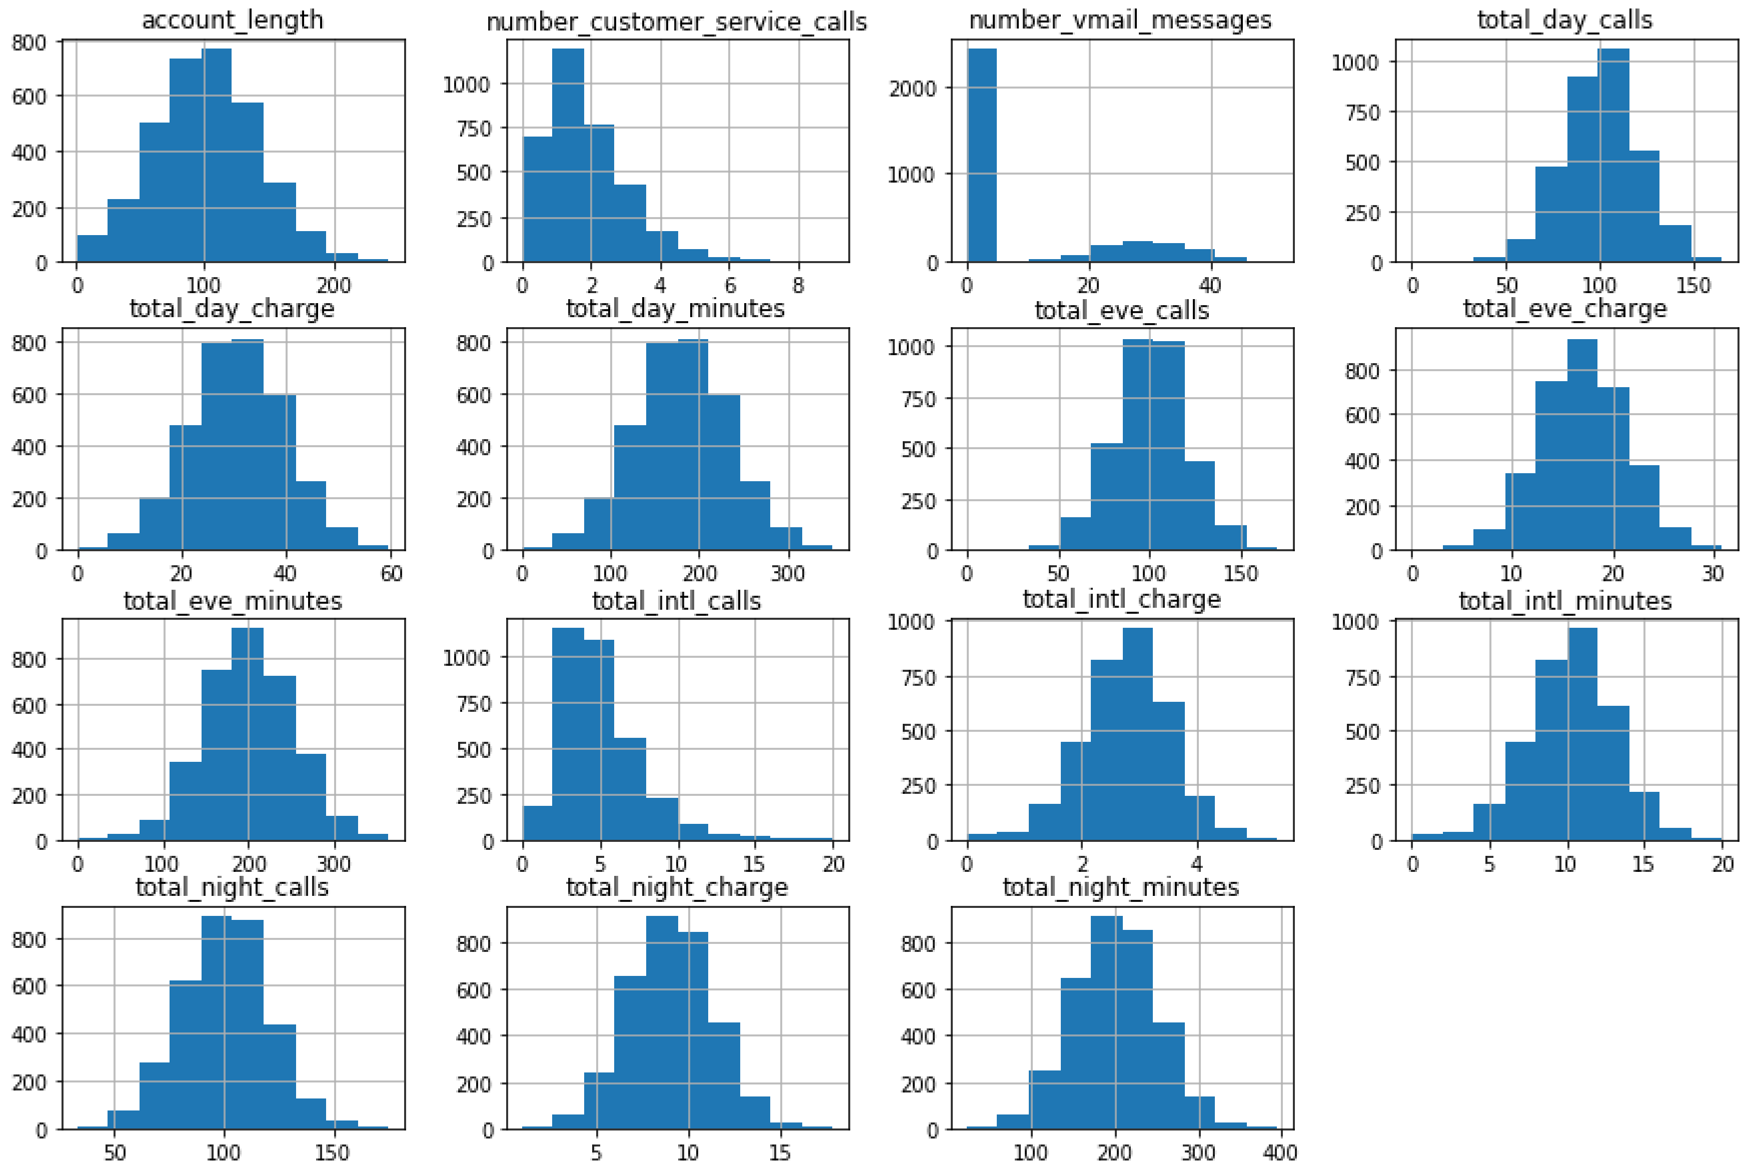

O dataset acima tem diversas variáves com distribuições normais.

In [110]:
```python
# Mapa de calor das correlações entre as variáveis.
sns.heatmap(df.corr())
```

Out[110]: <matplotlib.axes._subplots.AxesSubplot at 0x185e22a1390>

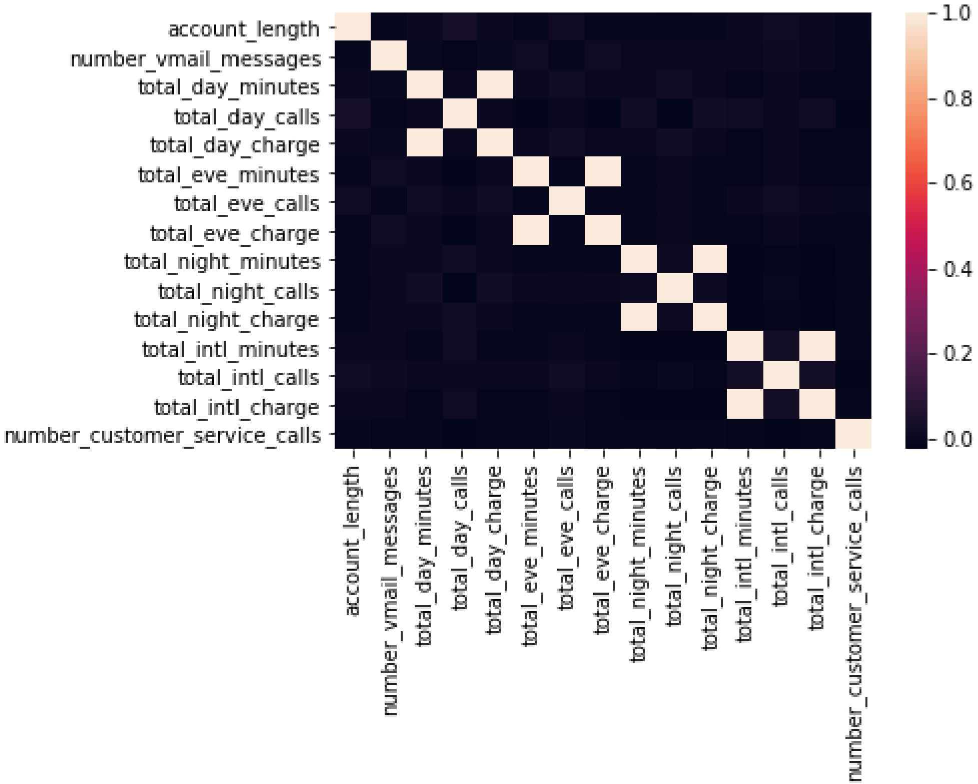

Do heatmap acima, podemos perceber que as variáveis total_day/eve/night_charges são colineares com seus pares total_day/eve/night_minutes, o que faz todo o sentido, visto que a cobrança de telefonemas é feita por minutos. Logo, podemos retirar os charges ou os minutos no momento de criar o modelo.

In [27]:

```
# Percentual da distribuição da variável target 'Churn'.
# Percebemos claro desbalanceamento.
df['churn'].value_counts(normalize=True)*100
```

Out[27]:

```
no     85.508551
yes    14.491449
Name: churn, dtype: float64
```

In [17]:

```
# Plot da variável target
sns.countplot(x='churn', data=df)
```

Out[17]:

```
<matplotlib.axes._subplots.AxesSubplot at 0x185d7c9c7b8>
```

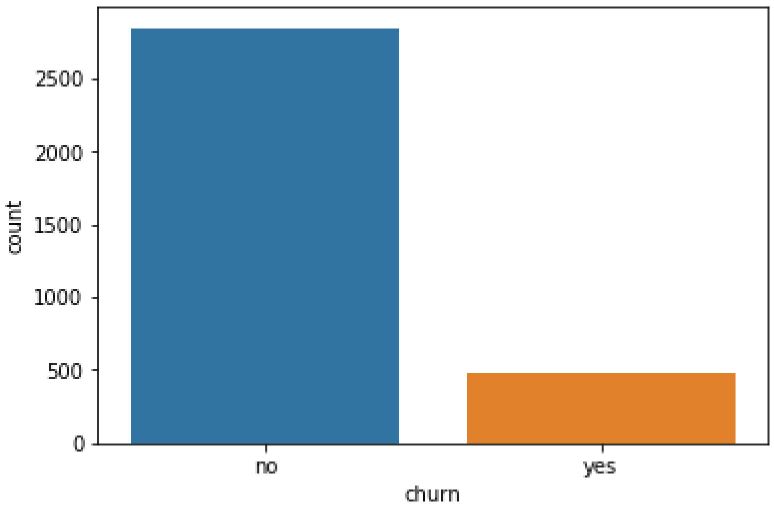

In [65]:
```
# Plot para visualizar fidelidade dos clientes por estado (5 maiores counts)
sns.countplot(x='churn', hue='state', data=df, hue_order=df.state.value_counts().iloc[:5].index)
```

Out[65]: <matplotlib.axes._subplots.AxesSubplot at 0x185db080c88>

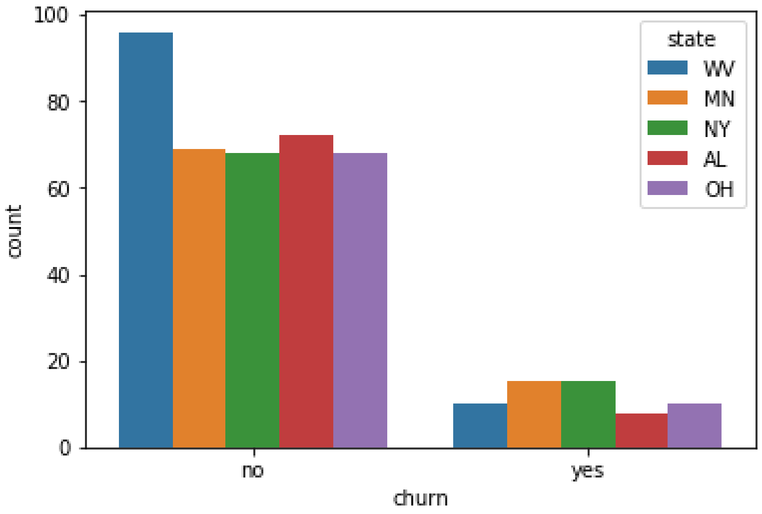

In [73]:
```
sns.countplot(x='international_plan', hue='churn', data=df)
```

Out[73]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x185de2834a8>
```

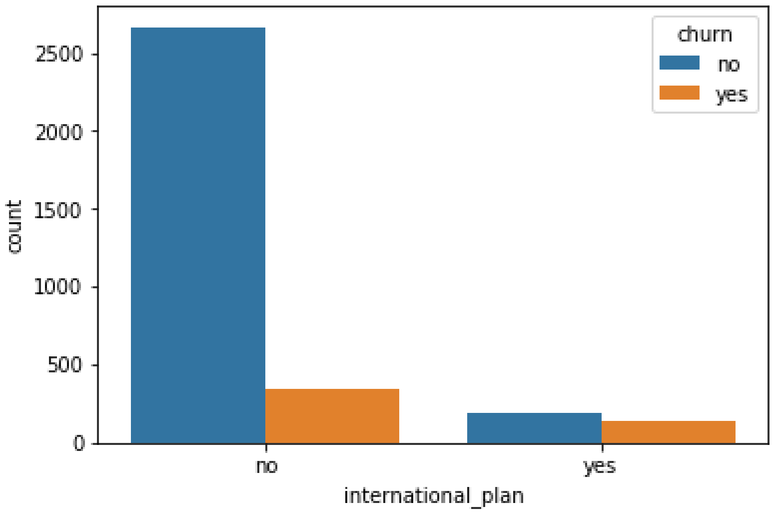

In [98]:
```
# Abaixo no gráifco podemos ver em qual quantidade de dias mais ocorre os cancelamentos
# Pelo BoxPlot de Churn='YES', vemos que os valores estão entre 80 e 130 -> 3 e 6 meses mais ou menos
sns.boxplot(y='churn', x='account_length', data=df).set_title('Período mais propenso para ocorrer o Churn')
```

Out[98]:
```
Text(0.5, 1.0, 'Período mais propenso para ocorrer o Churn')
```

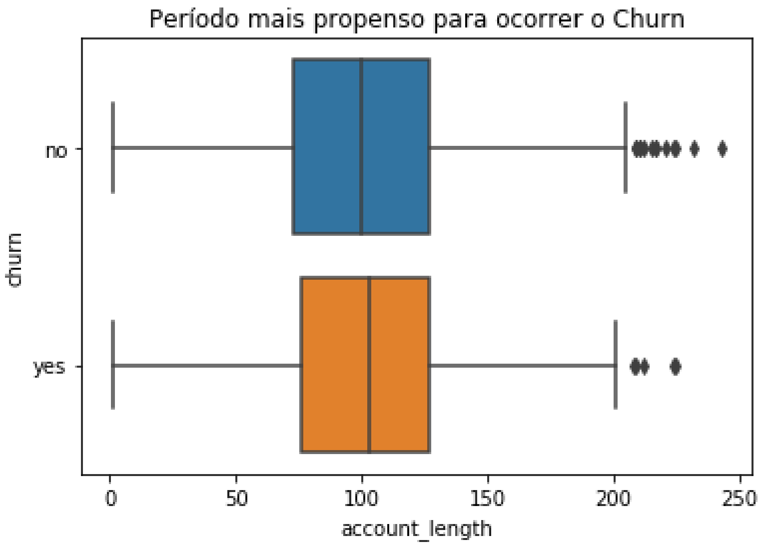

In [124]:
```
# Visualização do perfil de uso (minutos falados) das pessoas e sua fidelidade.
fig, axs = plt.subplots(ncols=3, figsize = (15,7))
sns.boxplot(y='churn', x='total_day_minutes', data=df, ax=axs[0]).set_title('Minutos falados dia vs Fidelidade')
sns.boxplot(y='churn', x='total_eve_minutes', data=df, ax=axs[1]).set_title('Minutos falados Tarde vs Fidelidade')
sns.boxplot(y='churn', x='total_night_minutes', data=df, ax=axs[2]).set_title('Minutos falados Noite vs Fidelidade')
```

Out[124]:
```
Text(0.5, 1.0, 'Minutos falados Noite vs Fidelidade')
```

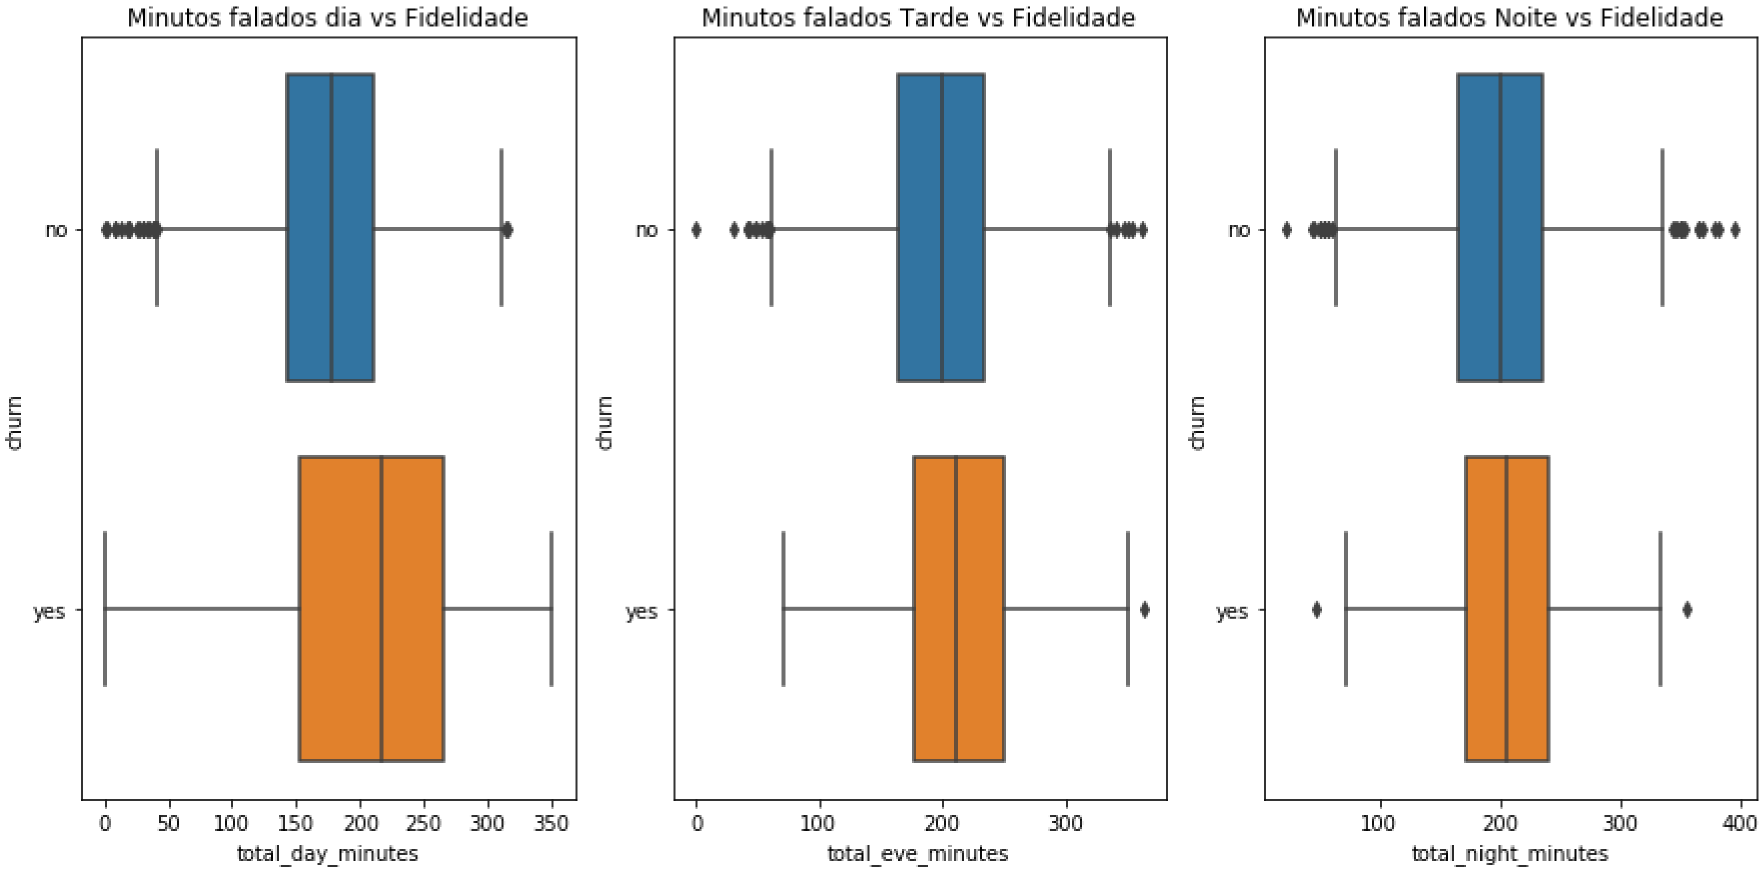

Percebemos que a maioria das pessoas que saem da empresa são, em geral, heavy users do serviço. Em média, os clientes que optam por trocar de empresa falam mais de 150 minutos, independentemente do período do dia.

Spark Session

In [203]:
```python
# Criando a Spark session
# Spark Session - usada quando se trabalha com Dataframes no Spark
spSession = SparkSession.builder.master("local").appName("LogRegr-Projeto4").getOrCreate()
```

In [204]:
```python
# Carregando o dataset e imprimindo o Schema, o qual nos mostra as colunas com nomes e tipos de dados.
new_df = spark.read.csv('projeto4_telecom_treino.csv', header=True, inferSchema=True)
new_df.printSchema()
```

```
root
 |-- _c0: integer (nullable = true)
 |-- state: string (nullable = true)
 |-- account_length: integer (nullable = true)
 |-- area_code: string (nullable = true)
 |-- international_plan: string (nullable = true)
 |-- voice_mail_plan: string (nullable = true)
 |-- number_vmail_messages: integer (nullable = true)
 |-- total_day_minutes: double (nullable = true)
 |-- total_day_calls: integer (nullable = true)
 |-- total_day_charge: double (nullable = true)
 |-- total_eve_minutes: double (nullable = true)
 |-- total_eve_calls: integer (nullable = true)
 |-- total_eve_charge: double (nullable = true)
 |-- total_night_minutes: double (nullable = true)
 |-- total_night_calls: integer (nullable = true)
 |-- total_night_charge: double (nullable = true)
 |-- total_intl_minutes: double (nullable = true)
 |-- total_intl_calls: integer (nullable = true)
 |-- total_intl_charge: double (nullable = true)
 |-- number_customer_service_calls: integer (nullable = true)
 |-- churn: string (nullable = true)
```

In [205]:

```
# Remover colunas 0 e area_code
drop_col = ['_c0', 'area_code']
new_df = new_df.select([column for column in new_df.columns if column not in drop_col])
new_df.groupby('churn').count().toPandas()
```

Out[205]:

	churn	count
0	no	2850
1	yes	483

In [206]:

```
# Transformando os dados de Churn em 0 para No e 1 para Yes.
from pyspark.sql.functions import when
def binarizar(labels):
    return when(labels == 'yes', 1).otherwise(0)
new_df = new_df.withColumn('label', binarizar(new_df['churn']))
```

In [207]:

```
# Remover coluna Categórica Churn.
drop_col = ['churn']
new_df = new_df.select([column for column in new_df.columns if column not in drop_col])
```

In [208]:

```
# Listando as variáveis categóricas e numéricas
cat_cols = [item[0] for item in new_df.dtypes if item[1].startswith('string')]
print(str(len(cat_cols)) + '  categorical features')
num_cols = [item[0] for item in new_df.dtypes if item[1].startswith('int') | item[1].startswith('double')][1:]
print(str(len(num_cols)) + '  numerical features')
```

```
3  categorical features
15  numerical features
```

In [209]:

```
# Inserir nova coluna com pesos para balancear a variável target
ratio = 0.85
def weight_balance(labels):
    return when(labels == '1', ratio).otherwise(1*(1-ratio))
new_df = new_df.withColumn('weights', weight_balance(new_df['label']))
```

In [210]:
```
# Usando o OneHotEncoderEstimator da MLlib Spark para converter as variáveis categoricas em números (one-hot vectors)
# Depois, usaremos o VectorAssembler para combinar o vetor resultante do one-hot com o restante das variáveis numéricas
# em um único vetor.
from pyspark.ml.feature import OneHotEncoderEstimator, StringIndexer, VectorAssembler
stages = []
for categoricalCol in cat_cols:
    stringIndexer = StringIndexer(inputCol = categoricalCol, outputCol = categoricalCol + 'Index')
    encoder = OneHotEncoderEstimator(inputCols=[stringIndexer.getOutputCol()], outputCols=[categoricalCol + "classVec"])
    stages += [stringIndexer, encoder]
    assemblerInputs = [c + "classVec" for c in cat_cols] + num_cols
assembler = VectorAssembler(inputCols=assemblerInputs, outputCol="features")
stages += [assembler]
```

In [211]:
```python
# Agora usamos um Pipeline para realizar todas as operações
from pyspark.ml import Pipeline
cols = new_df.columns
pipeline = Pipeline(stages = stages)
pipelineModel = pipeline.fit(new_df)
new_df = pipelineModel.transform(new_df)
selectedCols = ['features']+cols
new_df = new_df.select(selectedCols)
pd.DataFrame(new_df.take(5), columns=new_df.columns)
```

Out[211]:

	features	state	account_length	international_plan	voice_mail_plan	number_vmail_messages	total_day_minutes	total_day_calls	total_day_charge
0	(0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, ...	KS	128	no	yes	25	265.1	110	45.07
1	(0.0, 0.0, 0.0, 0.0, 0.0, 1.0, 0.0, 0.0, 0.0, ...	OH	107	no	yes	26	161.6	123	27.47
2	(0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, ...	NJ	137	no	no	0	243.4	114	41.38
3	(0.0, 0.0, 0.0, 0.0, 0.0, 1.0, 0.0, 0.0, 0.0, ...	OH	84	yes	no	0	299.4	71	50.90
4	(0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, ...	OK	75	yes	no	0	166.7	113	28.34

5 rows × 21 columns

In [212]:
```
# Fazer split dos dados em Treino e Teste sets
train, test = new_df.randomSplit([0.70, 0.3], seed = 1)
print('Treino:', train.count())
print('Teste:', test.count())
```

```
Treino: 2321
Teste: 1012
```

In [213]:
```
# Criando o modelo de Regressão Logística
from pyspark.ml.classification import LogisticRegression

LR = LogisticRegression(featuresCol = 'features', labelCol = 'label', maxIter=15)
LR_model = LR.fit(train)
```

In [214]:

```
# Plotando o ROC Curve para ver a performance do modelo de RL
trainingSummary = LR_model.summary
roc = trainingSummary.roc.toPandas()
plt.plot(roc['FPR'],roc['TPR'])
plt.ylabel('False Positive Rate')
plt.xlabel('True Positive Rate')
plt.title('ROC Curve')
plt.show()
print('Training set ROC: ' + str(trainingSummary.areaUnderROC))
```

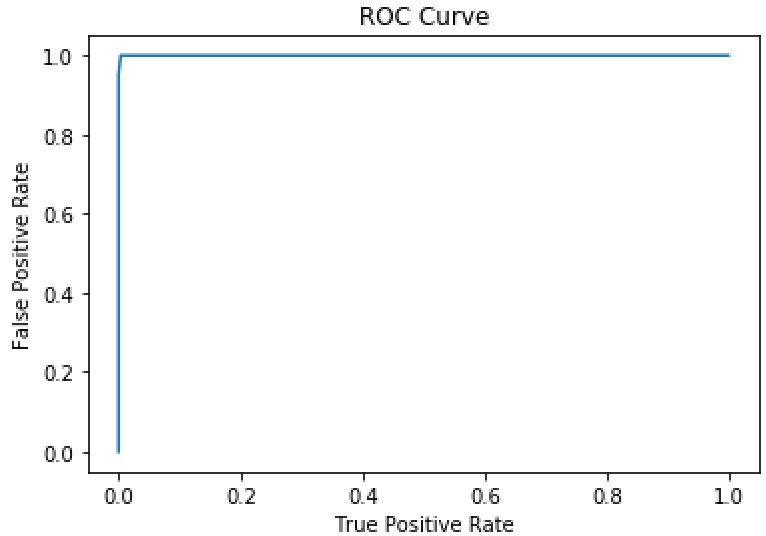


```
Training set ROC: 0.9999164495847843
```

In [215]:

```
# Print da performance do modelo
from pyspark.ml.evaluation import BinaryClassificationEvaluator
predictions_LR = LR_model.transform(test)
evaluator = BinaryClassificationEvaluator()
print("Test_SET (Area Under ROC): " + str(evaluator.evaluate(predictions_LR, {evaluator.metricName: "areaUnderROC"})))
```

```
Test_SET (Area Under ROC): 1.0
```

In [218]:
```python
# Confusion Matrix
predictions_LR.groupBy("label", "prediction").count().show()
```

```
+-----+----------+-----+
|label|prediction|count|
+-----+----------+-----+
|    0|       0.0|  867|
|    1|       1.0|  145|
+-----+----------+-----+
```

In [ ]: